Conociendo los datos

De dónde salen los datos, cómo están armados y qué tan confiables son

Ficha técnica del dataset – Proyecto integrador

Asignatura: Inteligencia de Negocios
Docente: Nancy Yaneth Gélvez García
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Carlos Stiven Mora Hoyos – 20261595003
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 28 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

1. Origen de los datos

Los datos vienen del material del caso entregado para el proyecto: un archivo CSV con el histórico transaccional de una empresa que vende en línea en España y Latinoamérica. Es un dataset **sintético**, construido para reproducir el comportamiento de un embudo comercial real, y viene acompañado de una evaluación del caso y de unos parámetros de referencia.

Cada fila es una **oportunidad comercial**: una persona que llegó por algún canal y que pudo terminar o no en una compra. El archivo original se conservó sin modificaciones; todo el trabajo se hizo sobre copias y vistas.

Tabla 1: Ficha general del dataset.

Característica	Valor
Formato	CSV, separado por comas
Registros	20.000 oportunidades
Columnas	28
Periodo	1 de enero de 2024 a 30 de abril de 2026 (28 meses)
Ventas	2.096 (conversión del 10,5 %)
Ingreso total	€2,33 millones
Contribución total	€1,54 millones

2. Estructura

Las 28 columnas se agrupan en siete bloques:

Tabla 2: Grupos de variables.

Grupo	Variables
Identificación y tiempo	Identificador, fecha, mes y trimestre
Perfil del cliente	Segmento, etapa del ciclo de vida, país y dispositivo
Origen	Canal, objetivo de la campaña y nivel de gasto en publicidad
Palancas comerciales	Variante de página y de botón, material descargable, pago simplificado, invitación y asistencia a webinar, oferta del producto nuevo
Calificación	Puntaje previo del interesado (1 a 99)
Resultado	Compra (sí/no) y días hasta el cierre
Valor	Ticket, ingreso, margen, utilidad bruta, costo atribuido y contribución

Tabla 3: Diccionario de variables.

Variable	Tipo	Descripción
`transaction_id`	Identificador	Código único de la oportunidad
`date, month, quarter`	Fecha	Día, mes y trimestre
`channel`	Categórica	Canal de llegada (7 valores)
`campaign_objective`	Categórica	Objetivo de la campaña (5 valores)
`customer_segment`	Categórica	Tipo de cliente (5 valores)
`lifecycle_stage`	Categórica	Visitante nuevo, contacto conocido o cliente recurrente
`device, geo_region`	Categórica	Dispositivo y país
`ad_budget_level`	Ordinal	Nivel de gasto en publicidad (bajo a saturado)
`campaign_daily_spend_eur`	Numérica	Gasto diario de la campaña
`cost_attributed_eur`	Numérica	Costo de publicidad atribuido a la oportunidad
`landing_variant, cta_variant`	Categórica	Versión de la página y del botón
`lead_magnet, checkout_simplified`	Binaria	Material descargable y pago simplificado
`webinar_invited, webinar_attended`	Binaria	Invitación y asistencia al webinar
`new_product_offer`	Binaria	Se le ofreció el producto nuevo
`lead_score`	Numérica	Puntaje del interesado (1 a 99)
`converted_to_sale`	Binaria	Compró (variable objetivo)
`days_to_close`	Numérica	Días hasta la compra
`aov_eur, revenue_eur`	Numérica	Ticket e ingreso
`gross_margin_pct, gross_profit_eur`	Numérica	Margen y utilidad bruta
`contribution_profit_eur`	Numérica	Contribución (utilidad después de costos)

3. Perfilamiento

3.1. Distribución de las variables principales

Tabla 4: Distribución de las categorías principales.

Variable	Distribución (registros)
Canal	Facebook Ads 4.599 · Google Ads 3.269 · Email 3.254 · SEO/Blog 3.083 · YouTube orgánico 2.391 · Afiliados 1.745 · Webinar 1.659
Segmento	B2B Services 4.899 · Ecommerce 4.724 · SMB 4.377 · Creator 4.008 · Enterprise 1.992
País	España 9.228 · México 3.564 · Colombia 1.996 · Argentina 1.978 · Chile 1.652 · EE. UU. hispano 1.582
Dispositivo	Escritorio 11.590 · Móvil 7.116 · Tableta 1.294
Ciclo de vida	Visitante nuevo 10.711 · Contacto conocido 6.846 · Cliente recurrente 2.443
Gasto en publicidad	Orgánico 12.132 · Medio 3.290 · Alto 2.029 · Saturado 1.762 · Bajo 787

El puntaje del interesado va de 1 a 99 con promedio de 56,9. Solo el 10,5 % de las oportunidades termina en compra, así que la variable objetivo está desbalanceada.

3.2. Conversión por canal

Tabla 5: Resumen por canal.

Canal	Registros	Conversión	Ingreso (€)	Contribución (€)
Email	3.254	19,1 %	680.292	505.200
Webinar	1.659	17,5 %	355.556	253.968
SEO / Blog	3.083	12,2 %	420.311	300.375
YouTube orgánico	2.391	10,8 %	284.802	207.307
Afiliados	1.745	7,3 %	136.072	78.113
Google Ads	3.269	6,1 %	221.094	111.850
Facebook Ads	4.599	4,8 %	228.624	84.433

Los canales pagados traen más volumen pero convierten menos; los propios (email, webinar, contenido) convierten más y dejan más contribución.

4. Calidad de los datos

4.1. Validaciones

Se revisaron cuatro frentes y **ninguna regla presentó fallas**:

- **Unicidad y completitud**: no hay identificadores repetidos ni nulos en los campos clave.
- **Coherencia temporal**: el mes y el trimestre coinciden con la fecha.
- **Dominios**: las binarias solo toman 0 y 1, el puntaje está entre 1 y 99 y el margen entre 0 y 1.
- **Coherencia entre columnas**: nadie asiste a un webinar sin invitación, los días de cierre solo existen si hubo venta, el ingreso cuadra con el ticket y el margen, y solo los canales pagados tienen nivel de gasto en publicidad.

4.2. Hallazgos

Aunque el dato está limpio, el perfilamiento mostró particularidades que había que tener en cuenta:

Tabla 6: Hallazgos del perfilamiento y tratamiento.

Hallazgo	Descripción	Tratamiento
Costo fijo oculto	En las 2.096 ventas la contribución es €22 menor de lo esperado	Se documentó como costo fijo por venta
Gasto diario no sumable	El gasto diario de campaña cambia en cada fila; sumarlo da una cifra sin sentido	Solo se promedia; para sumar se usa el costo atribuido
Ceros estructurales	Sin venta, el ticket vale 0 y los días de cierre quedan vacíos (17.904 filas)	El ticket se calcula solo sobre ventas y los vacíos no se imputan
Variables posteriores a la venta	Ingreso, margen, contribución y días de cierre solo se conocen después	No se usan para predecir la compra
Producto nuevo limitado	Solo se ofreció en tres segmentos (B2B Services, Ecommerce y Enterprise)	Se compara dentro de cada segmento
Último trimestre incompleto	2026T2 solo tiene abril	Se marca como parcial en las comparaciones

5. Conclusión

El dataset es completo y consistente: 20.000 oportunidades en 28 meses, sin nulos ni duplicados en los campos clave y sin fallas en las reglas de validación. Las particularidades encontradas (costo fijo, gasto no sumable, ceros estructurales y variables posteriores a la venta) no son errores, sino características que se deben respetar al calcular indicadores y al construir modelos.