



¿En qué invertir para crecer el próximo año?

Del dato transaccional a una decisión de inversión: preparación, modelo dimensional, modelo de conversión y simulación de escenarios

Proyecto integrador

Asignatura: Inteligencia de Negocios
Docente: Nancy Yaneth Gélvez García
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Carlos Stiven Mora Hoyos – 20261595003
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 7 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

Resumen

La gerencia de una empresa de venta en línea tiene cuatro iniciativas sobre la mesa para el próximo año (rediseñar el embudo de compra, un programa de webinars, duplicar la inversión en publicidad y lanzar un producto premium) y quiere saber en cuál invertir. Trabajamos sobre 20.000 oportunidades comerciales registradas entre enero de 2024 y abril de 2026. Primero validamos el archivo con reglas en SQL y construimos un esquema estrella; luego calculamos indicadores, ajustamos una regresión logística para estimar la probabilidad de compra y la usamos para simular qué habría pasado con cada iniciativa. La incertidumbre se trató en dos capas: *bootstrap* sobre los datos y Monte Carlo sobre los costos y el alcance de la ejecución.

El resultado principal es que duplicar la publicidad destruye valor en casi todos los escenarios, que el embudo mejorado ofrece la ganancia más estable (unos €120 mil de contribución adicional al año) y que el producto nuevo tiene el mayor potencial (€175 mil) pero descansa sobre apenas 55 ventas. Recomendamos extender el embudo con un grupo de control, pilotear el producto antes de escalarlo y no aumentar la pauta. Los datos son sintéticos: el método es transferible, las cifras no describen a una empresa real.

Índice

1. El problema de negocio	3
2. Preparación y validación de los datos	3
2.1. El archivo	4
2.2. Reglas de validación	4
2.3. Lo que encontramos al perfilar	4
3. Modelo dimensional e indicadores	4
3.1. Esquema estrella	4
3.2. Indicadores	5
4. Modelo de conversión	6
4.1. Especificación	6
4.2. Evaluación temporal	6
4.3. Qué aprendió el modelo	7
5. De la predicción a la decisión	7
5.1. Escenarios contrafactuales	7
5.2. Dos capas de incertidumbre	8
6. Resultados	8
6.1. P1. Crecimiento	8
6.2. P2. Dónde está el valor	8
6.3. P3. Qué explica la mejora	10
6.4. P4. Publicidad	10
6.5. P5. Qué hace que alguien compre	12
6.6. P6. Qué iniciativa conviene	12
7. Limitaciones	12
8. Conclusiones y recomendación	13
A. Diccionario de variables	14
B. Reproducción	14
C. Código SQL	14

1. El problema de negocio

La empresa vende en línea en España y Latinoamérica y registra cada oportunidad comercial: el canal por el que llegó la persona, el tipo de cliente, la versión de la página que vio, si la invitaron a un webinar, si le ofrecieron el producto nuevo y si al final compró. Con esa información la gerencia debe repartir el presupuesto del próximo año entre cuatro opciones:

Tabla 1: Iniciativas evaluadas.

Iniciativa	En qué consiste
Embudo mejorado	Llevar a toda la web la página de llegada, el botón, el material descargable y el pago simplificado que ya se probaron con una parte del tráfico
Webinars	Invitar a un webinar a los contactos que ya conocen la marca y no han sido invitados
Duplicar publicidad	Doblar el gasto diario en Facebook Ads y Google Ads
Producto nuevo	Ofrecer un producto premium de mayor precio

Decidimos medir todo en **contribución**: lo que queda de cada venta después de descontar el costo del producto, la publicidad atribuida y un costo fijo de despacho. No es la utilidad neta contable (no descuenta gastos fijos ni impuestos), pero es la medida correcta para comparar iniciativas, porque una venta que cueste más en publicidad de lo que deja aumenta los ingresos y aun así hace perder dinero.

Para ordenar el trabajo planteamos seis preguntas, que se responden en la sección 6:

- P1. ¿El negocio está creciendo de forma sana?
- P2. ¿Qué canales y tipos de cliente generan más contribución?
- P3. ¿Qué explica la mejora observada en 2025?
- P4. ¿Más publicidad trae más contribución?
- P5. ¿Qué variables explican que una persona compre?
- P6. ¿Qué iniciativa deja más contribución y con qué riesgo?

La figura 1 resume el recorrido técnico. Todo el proceso se regenera con `make run` y cada cifra de este informe indica la vista SQL o el archivo de salidas/ del que sale.




Figura 1: Flujo del proyecto. El archivo original nunca se modifica: toda transformación es una vista SQL.

2. Preparación y validación de los datos

2.1. El archivo

El archivo tiene 20.000 filas y 28 columnas; cada fila es una oportunidad comercial. Las columnas se agrupan en identificación y tiempo (id, fecha, mes, trimestre), perfil del cliente (segmento, etapa, país, dispositivo), origen (canal, objetivo de campaña, nivel de gasto en publicidad), palancas que la empresa controla (variantes de página y botón, material descargable, pago simplificado, webinar, oferta del producto nuevo), resultado (compra y días hasta el cierre) y valor (ingreso, margen, costo atribuido y contribución). El diccionario completo está en el anexo A.

Sobre esa base la vista `ventas` agrega tres columnas derivadas: si la oportunidad vio el embudo mejorado completo (las cuatro mejoras a la vez), si llegó por publicidad pagada y su estado frente al webinar (no invitada, invitada o asistente).

2.2. Reglas de validación

La vista `validacion` cuenta, para cada regla, cuántas filas la incumplen, y el *pipeline* se detiene si alguna es distinta de cero. Las reglas cubren cuatro frentes:

- **Unicidad y completitud:** identificadores repetidos y valores nulos, tanto en los campos clave como en los atributos que usan el modelo y las dimensiones.
- **Coherencia temporal:** el mes y el trimestre deben corresponder a la fecha.
- **Dominios:** binarios en {0, 1}, puntaje entre 1 y 99, margen entre 0 y 1.
- **Coherencia entre columnas:** nadie asiste a un webinar sin invitación; los días de cierre solo existen si hubo venta; el ingreso es el ticket por la venta; la utilidad bruta es el ingreso por el margen; la contribución cuadra con la utilidad bruta, el costo atribuido y el costo fijo; los canales pagados, y solo ellos, tienen nivel de gasto en publicidad.

Las quince reglas dan cero (`salidas/validacion.csv`).

Probamos además una regla que resultó falsa y por eso no quedó: que el gasto diario de campaña fuera único por canal y día. Falló en 7.764 de las 7.868 filas pagadas, y eso cambió la forma de tratar esa columna (ver el segundo hallazgo de la tabla siguiente).

2.3. Lo que encontramos al perfilar

Que las reglas den cero no significa que el dato se pueda usar tal cual. Siete hallazgos cambiaban las conclusiones si se pasaban por alto:

3. Modelo dimensional e indicadores


3.1. Esquema estrella

Para que el análisis se pueda repetir en Power BI, Tableau o una tabla dinámica, separamos los datos en un esquema estrella (`sql/03_modelo_dimensional.sql`, figura 2). La tabla de hechos principal tiene el grano de la oportunidad. El gasto diario de campaña vive en otra tabla, con un registro por canal, día y nivel de pauta: como no es aditivo, guarda su promedio como gasto de referencia y no debe sumarse en el tablero. El perfil del

Tabla 2: Hallazgos del perfilamiento y tratamiento.

Hallazgo	Por qué importa	Tratamiento
Costo fijo oculto	La contribución no cuadraba en las 2.096 ventas: siempre faltaban €22	Se documentó como costo fijo por venta y se volvió regla de validación
Gasto diario que no se puede sumar	El gasto diario de campaña toma un valor casi distinto en cada fila (7.502 valores en 7.868 filas) y sube con el nivel de pauta: describe el régimen de gasto, no un desembolso. Sumarlo da €4,55 M, una cifra sin sentido	Se trata como medida no aditiva: solo se promedia, por día y por nivel, y nunca se suma
Sin gasto total de pauta	El único costo de publicidad que se puede sumar es el atribuido a cada oportunidad (€117 mil en Facebook y Google); no sabemos si cubre todo lo pagado	Se usa el atribuido, que es el que entra en la contribución; el gasto real queda como pregunta para finanzas
Ceros estructurales	El ticket vale 0 y los días de cierre están vacíos cuando no hay venta (90 % de las filas)	El ticket se calcula solo sobre ventas (€1.100 aprox. y no €116) y los vacíos no se imputan
Variables posteriores a la venta	Ingreso, margen, contribución y días de cierre solo se conocen después	Se excluyen del modelo para evitar fuga de información
Producto ofrecido a pocos	Solo se ofreció en B2B Services, Ecommerce y Enterprise, segmentos de ticket alto	Se compara dentro de cada segmento y no se extrapola a los demás
Palancas que cambian por periodos	El nivel de pauta y el embudo cambiaron por épocas, y 2026T2 solo tiene abril	El modelo controla por trimestre; las figuras marcan el trimestre incompleto

cliente se agrupa en una dimensión “basura” (segmento, etapa, país y dispositivo), y la experiencia (variantes del embudo, webinar, oferta) en otra.

**Figura 2:** Esquema estrella con dos tablas de hechos de grano distinto.

La vista `control_estrella` comprueba que las claves de cada dimensión sean únicas y que, al volver a unir los hechos con la dimensión de fecha, se recuperen exactamente las 20.000 filas, los €2,33 millones de ingresos y la contribución total del archivo. Si algo de eso falla, la ejecución se detiene antes de exportar las tablas a `data/modelo_dimensional/`.

3.2. Indicadores

Dos aclaraciones. El CAC se calcula con el costo atribuido, el único que se puede sumar; si el gasto real de pauta es mayor, el CAC verdadero también lo es, así que debe leerse como una cota inferior. Y lo calculamos sobre todas las ventas, incluidas las de clientes que regresan, así que no es estrictamente el costo de adquirir un cliente nuevo.

Tabla 3: Indicadores del proyecto.

Indicador	Pregunta	Cálculo
Conversión	¿Qué proporción compra?	ventas / oportunidades
Ticket medio	¿Cuánto vale una venta?	ingresos / ventas
Costo por venta (CAC)	¿Cuánto cuesta en publicidad cada venta?	costo atribuido / ventas
ROAS	¿Cuánto ingreso deja cada euro de pauta?	ingresos / costo atribuido
Contribución por oportunidad	¿Cuánto vale cada interesado que llega?	contribución / oportunidades
Adopción del embudo	¿Qué tan extendida está la mejora?	oportunidades con las 4 mejoras / total

El indicador que más usamos es la contribución por oportunidad, porque en un solo número junta si la gente compra, cuánto paga y cuánto costó traerla. La vista `kpi` lo calcula, junto con los demás, para doce dimensiones (canal, segmento, país, mes, trimestre, etc.) en formato largo (`salidas/kpi.csv`).

4. Modelo de conversión

4.1. Especificación

Usamos una regresión logística sobre la variable `converted_to_sale`. La elegimos por encima de modelos más flexibles porque el objetivo no era ganar puntos de AUC sino comparar escenarios, y para eso necesitábamos coeficientes interpretables y probabilidades razonablemente calibradas.

Solo entran variables conocidas antes de la venta: canal, objetivo de campaña, segmento, etapa del cliente, dispositivo, país, nivel de pauta, variantes de página y botón, material descargable, pago simplificado, invitación y asistencia al webinar, oferta del producto nuevo, puntaje previo del interesado y trimestre. Las categóricas se codifican con *one-hot* y el puntaje se estandariza.

4.2. Evaluación temporal

Entrenamos con 2024 y 2025 y evaluamos en enero–abril de 2026 (3.632 oportunidades), que es como se usaría el modelo en la práctica: aprender del pasado y puntuar lo que viene.

Tabla 4: Desempeño fuera del periodo de entrenamiento (`salidas/lift_2026.csv`).

Medida	Resultado	Lectura
AUC	0,745	Entre un comprador y un no comprador tomados al azar, el modelo puntúa más alto al comprador tres de cada cuatro veces
Conversión del 10 % con mayor puntaje	33,5 %	2,6 veces la conversión media de 2026 (12,8 %)
Ventas en el 20 % con mayor puntaje	43 %	Priorizar ese grupo rinde más del doble que atender al azar




Figura 3: Conversión real en 2026 por decil de puntaje del modelo entrenado con 2024–2025.

4.3. Qué aprendió el modelo

La tabla 5 muestra cómo cambian las chances de compra (probabilidad de comprar sobre probabilidad de no comprar) con cada factor, manteniendo lo demás constante. Como el *one-hot* conserva todas las categorías, los coeficientes de una variable categórica solo tienen sentido comparados con una categoría de referencia; `salidas/drivers.csv` los reporta así.

Tabla 5: Efecto sobre las chances de compra (`salidas/drivers.csv`).

Factor	Frente a	Efecto
Puntaje previo una desviación estándar más alto	la media	+82 %
Asistir al webinar (además de estar invitado)	no asistir	+43 %
Botón centrado en el beneficio	botón estándar	+24 %
Página de llegada nueva	página base	+17 %
Material descargable	sin material	+16 %
Pago simplificado	pago estándar	+5 %
Pauta en nivel saturado	nivel medio	−49 %
Oferta del producto nuevo	sin oferta	−38 %

El efecto del producto es negativo en conversión, pero cada venta del producto vale más del doble (ticket de €2.827 frente a €1.064), así que el balance en contribución puede ser positivo. Es justo lo que la simulación tiene que resolver.

5. De la predicción a la decisión

5.1. Escenarios contrafactuales

Tomamos las 10.073 oportunidades de los últimos doce meses y le pedimos al modelo la contribución esperada de cada una dos veces: tal como ocurrió y con la iniciativa aplicada. La diferencia es la ganancia atribuible a la

iniciativa. La contribución esperada de una oportunidad es su probabilidad de compra por el valor de una venta de su segmento (utilidad bruta menos el costo fijo de €22), menos el costo de publicidad atribuido.

- **Embudo:** todas las oportunidades ven las cuatro mejoras.
- **Webinars:** se invita a los 3.334 contactos conocidos que no lo fueron, y asiste uno de cada cuatro, como en el histórico.
- **Producto:** se ofrece a las 5.858 oportunidades de los tres segmentos donde hay evidencia.
- **Publicidad:** como hubo periodos con gasto alto y saturado, se usa la contribución observada en esos regímenes, escalada por el volumen de oportunidades por día de campaña. Duplicar el gasto actual (nivel medio) cae entre los niveles alto y saturado.

5.2. Dos capas de incertidumbre

La primera es la de los datos: repetimos el ajuste del modelo y el cálculo de todos los escenarios en 200 muestras *bootstrap* del histórico. La segunda es la de la ejecución: ninguna iniciativa cuesta ni llega exactamente a lo planeado, así que en 10.000 simulaciones combinamos una réplica *bootstrap* con costos y alcances tomados de distribuciones triangulares:

Tabla 6: Supuestos de ejecución a doce meses (SUPUESTOS en `src/bi/model.py`).

Iniciativa	Costo de implementación (mín. / probable / máx.)	Alcance
Embudo	€8 mil / €12 mil / €20 mil (diseño, desarrollo y pruebas A/B)	70–100 %
Webinars	€9,6 mil / €14,4 mil / €24 mil (12 sesiones al año)	50–100 %
Publicidad	€0 / €2 mil / €5 mil (gestión; la pauta ya está en los datos)	100 %
Producto	€15 mil / €25 mil / €45 mil (desarrollo y lanzamiento)	30–90 %

Estos costos son supuestos nuestros y no salen de los datos. Por eso en la sección 6.6 indicamos cuánto tendrían que cambiar para que cambie la recomendación.

6. Resultados

6.1. P1. Crecimiento

La tabla siguiente compara los últimos doce meses (mayo de 2025 a abril de 2026) con los doce anteriores. Las cifras salen de `salidas/crecimiento.csv`.

Las ventas crecen más que las oportunidades y la contribución más que las ventas: el crecimiento viene sobre todo de vender mejor, no de traer más gente. La señal de alerta es que el gasto total en publicidad atribuido sube 44 %, y no sabemos si ese costo atribuido recoge todo lo que realmente se pagó.

6.2. P2. Dónde está el valor

Facebook y Google traen el 39 % de las oportunidades pero solo el 13 % de la contribución. Email, SEO y Webinar, en cambio, traen el 40 % de las oportunidades y el 69 % de la contribución. Por segmento, Enterprise

Tabla 7: Últimos doce meses frente a los doce anteriores.

Indicador	Año anterior	Último año	Cambio
Oportunidades	7.680	10.073	+31 %
Ventas	694	1.224	+76 %
Conversión	9,0 %	12,2 %	+3,2 p.p.
Costo por venta	€81	€66	−18 %
Contribución	€487 mil	€934 mil	+92 %




Figura 4: Ingresos y contribución por mes (vista kpi, dimensión mes).

es el 10 % de las oportunidades y aporta el 24 % de la contribución. España concentra el 47 % de los ingresos, pero la rentabilidad por oportunidad es parecida en todos los países, así que el país no cambia la decisión (`salidas/pivote_ingresos_region_segmento.csv`).




Figura 5: Contribución por oportunidad y conversión por canal (vista kpi, dimensión canal).

6.3. P3. Qué explica la mejora

La conversión pasa de cerca de 9 % a cerca de 13 % en el tercer trimestre de 2025, el mismo trimestre en que el embudo completo empieza a usarse (16 % de las oportunidades). Dentro de cada trimestre el modelo encuentra que las oportunidades con las mejoras compran más, lo que apoya la idea de que el embudo tiene un efecto propio.

Pero el dato mensual obliga a ser cautos. En julio de 2025 la conversión ya es de 13,5 % cuando ninguna oportunidad tenía todavía el embudo completo; y en el cuarto trimestre la adopción sube a 24 % mientras la conversión baja a 11,8 %. Además, entre junio y julio el costo por venta cae de €160 a €46, lo que sugiere que terminó un periodo de pauta saturada y cambió la mezcla de canales. Nuestra lectura es que el embudo explica una parte de la mejora, no toda, y que el salto de julio tiene al menos otra causa que no podemos aislar con estos datos. Confirmarlo requiere revisar cuándo se activó cada componente por separado y si hubo otros cambios (precios, equipo comercial) en esas fechas.

6.4. P4. Publicidad

Pasar del nivel medio de gasto (el vigente) al saturado multiplica el gasto diario por 2,5 pero las oportunidades solo por 1,3, y además llegan peor calificadas: el puntaje medio baja de 52,5 a 37,8. Cada venta pasa a costar €853 en vez de €178, y cada oportunidad deja –€3 en lugar de €36 (`salidas/ads_niveles.csv`).

Una salvedad: los niveles de gasto funcionaron como épocas, no como un experimento. El nivel bajo, por ejemplo, solo existió antes de que llegara el embudo. La dirección del resultado es muy clara, pero su magnitud mezcla el efecto del gasto con el del momento.




Figura 6: Conversión y adopción del embudo completo por trimestre (vista kpi, dimensión trimestre).

Facebook y Google según el nivel de gasto diario




Figura 7: Costo por venta y contribución por oportunidad según el nivel de gasto (vista ads_niveles).

6.5. P5. Qué hace que alguien compre

El puntaje previo es, de lejos, el factor más fuerte, seguido por la asistencia al webinar y las mejoras del embudo (tabla 5). Fuera de muestra, el modelo ordena bien a los interesados, así que además de servir para comparar iniciativas puede usarse para que el equipo comercial priorice a quién llamar. Para ese uso conviene reentrenarlo sin la variable de trimestre, que no aporta nada al puntuar periodos futuros, y revisar su calibración.

6.6. P6. Qué iniciativa conviene

Tabla 8: Contribución adicional a doce meses en 10.000 simulaciones (salidas/montecarlo_resumen.csv).

Iniciativa	Esperado	P10	P90	P(pérdida)
Producto nuevo (3 segmentos)	€175 mil	€75 mil	€285 mil	0,1 %
Embudo mejorado	€120 mil	€77 mil	€166 mil	0,0 %
Webinars	€32 mil	€8 mil	€56 mil	3,9 %
Duplicar publicidad	–€101 mil	–€158 mil	–€45 mil	99,5 %

Contribución adicional a 12 meses: valor esperado y rango P10-P90




Figura 8: Valor esperado (punto) y rango entre los percentiles 10 y 90 (barra) por iniciativa.

El producto tiene el mayor valor esperado y también el rango más ancho. El embudo deja algo menos, pero con un rango estrecho y con el mejor retorno por euro invertido (unas nueve veces su costo, frente a seis del producto). Duplicar la publicidad pierde dinero en prácticamente todas las simulaciones.

Los umbrales que cambiarían la recomendación son dos. Si lanzar el producto costara más de €84 mil, el embudo pasaría a tener el mayor valor esperado. Y los webinars solo compensan si el programa cuesta menos de €48 mil al año.

7. Limitaciones

Las probabilidades de pérdida de la tabla anterior hay que leerlas con cuidado. Recogen el ruido muestral y la incertidumbre de ejecución, pero suponen que el modelo está bien especificado. Hay cuatro razones para pensar

que la incertidumbre real es mayor:

1. **El producto se estima con muy poca evidencia.** Se ofreció 554 veces y se vendió 55. El escenario lo extiende a casi diez veces más oportunidades y no considera canibalización ni efecto novedad. Su cifra debe tomarse como un techo optimista, no como una estimación central.
2. **El *bootstrap* remuestrea filas sueltas.** Las palancas cambiaron por épocas, y remuestrear fila por fila ignora esa estructura. Un *bootstrap* por bloques mensuales daría rangos más anchos.
3. **Los efectos del webinar y del embudo no salen de experimentos.** Quienes asisten a un webinar se seleccionan solos, y a los invitados se les eligió con mejor puntaje (62 frente a 56). Es probable que el +43 % de la asistencia sobreestime el efecto real.
4. **Las iniciativas se evaluaron por separado.** El embudo sube la conversión y el producto la baja; en un modelo logístico esos efectos no se suman. Antes de ejecutar ambas habría que simular el escenario combinado.

Por último, los datos son sintéticos. El método se puede reutilizar con datos reales; las cifras no describen a ninguna empresa.

8. Conclusiones y recomendación

El negocio crece por eficiencia: convierte mejor y gasta menos por venta. La publicidad pagada es la parte menos rentable de la operación, y llevarla a niveles altos de gasto la vuelve deficitaria. Entre las iniciativas, el embudo mejorado es la apuesta más segura y el producto nuevo la de mayor potencial, aunque también la menos respaldada por los datos.

Nuestra recomendación a la gerencia:

1. **Extender el embudo mejorado**, que hoy ve cerca de una de cada cuatro oportunidades. Hacerlo dejando un grupo de control al azar, para medir su efecto de forma limpia y no depender solo de la comparación histórica.
2. **Pilotear el producto nuevo** durante un trimestre en B2B Services, Ecommerce y Enterprise, ofreciéndolo a un grupo elegido al azar. Escalarlo solo si el piloto confirma que compensa la menor conversión.
3. **No duplicar la publicidad.** Mantener el nivel actual y pedir a finanzas el gasto real de pauta, que el archivo no trae.
4. **Webinars solo si cuestan menos de €48 mil al año**, y medir asistentes, no invitados.
5. **Usar el puntaje del modelo** para ordenar la atención comercial.

A. Diccionario de variables

Variable	Tipo	Descripción y uso
transaction_id	Identificador	Una oportunidad; se valida que no se repita
date	Fecha	Día de la oportunidad
month, quarter	Fecha derivada	Mes y trimestre; se valida que coincidan con la fecha
channel	Categoría	Canal de llegada (7 valores)
campaign_objective	Categoría	Objetivo de la campaña (captación, nutrición, recuperación...)
customer_segment	Categoría	B2B Services, Enterprise, Ecommerce, Creator, SMB
lifecycle_stage	Categoría	Visitante nuevo, contacto conocido o cliente recurrente
device, geo_region	Categoría	Dispositivo y país
ad_budget_level	Ordinal	Nivel de gasto en pauta (bajo a saturado); solo canales pagados
campaign_daily_spend_eur	Numérica	Gasto diario de la campaña; varía por fila y no es aditivo
cost_attributed_eur	Numérica	Costo de pauta atribuido; entra en la contribución, no en el modelo
landing_variant, cta_variant	Categoría	Variantes de página y botón (palancas del embudo)
lead_magnet, checkout_simplified	Binaria	Material descargable y pago simplificado
webinar_invited, webinar_attended	Binaria	Invitación y asistencia al webinar
new_product_offer	Binaria	Se ofreció el producto nuevo
lead_score	Numérica (1–99)	Puntaje previo del interesado; la variable más predictiva
converted_to_sale	Binaria	Compró; variable objetivo
days_to_close	Numérica	Días hasta la compra; solo si compró; excluida (fuga)
aov_eur, revenue_eur	Numérica	Ticket e ingreso; 0 si no compró
gross_margin_pct, gross_profit_eur	Numérica	Margen y utilidad bruta; excluidas del modelo
contribution_profit_eur	Numérica	Contribución; medida de valor del informe

B. Reproducción

```
make install # entorno con uv
make test # pruebas automáticas
make run # valida, calcula, entrena, simula y regenera salidas y figuras
make pdf # compila este informe y la presentación (tectonic)
```

El archivo original debe estar en `data/original/dataset_ventas_transaccional_sintetico_es.csv`.

C. Código SQL

sql/01_preparacion.sql

```

-- Expects a view/table `raw` with the original CSV (see bi.pipeline.connect).
-- The original file is never modified: everything here is a view.

create or replace view ventas as
select
  * replace (cast(date as date) as date),
  landing_variant = 'landing_v2' and cta_variant = 'benefit_cta'
    and lead_magnet = 1 and checkout_simplified = 1 as funnel_completo,
  ad_budget_level <> 'organic_or_owned' as es_pago,
  case when webinar_attended = 1 then 'asistio'
        when webinar_invited = 1 then 'invitado'
        else 'no_invitado' end as estado_webinar
from raw;

-- One row per rule; `fallas` = rows breaking it. All must be 0 before analysis.
create or replace view validacion as
select 'id_duplicado' as regla, count(*) - count(distinct transaction_id) as fallas from ventas
union all select 'nulos_en_campos_clave', count(*) filter (
  where transaction_id is null or date is null or channel is null
    or converted_to_sale is null or contribution_profit_eur is null) from ventas
union all select 'nulos_en_atributos', count(*) filter (
  where customer_segment is null or lifecycle_stage is null or device is null or geo_region is null
    or campaign_objective is null or ad_budget_level is null or landing_variant is null or
    cta_variant is null
    or lead_score is null or lead_magnet is null or checkout_simplified is null or webinar_invited
    is null
    or webinar_attended is null or new_product_offer is null or revenue_eur is null
    or cost_attributed_eur is null or gross_profit_eur is null) from ventas
union all select 'mes_distinto_a_fecha', count(*) filter (where month <> strftime(date, '%Y-%m'))
  from ventas
union all select 'trimestre_distinto_a_fecha', count(*) filter (
  where quarter <> year(date)::varchar || 'Q' || quarter(date)::varchar) from ventas
union all select 'binarios_fuera_de_0_1', count(*) filter (
  where lead_magnet not in (0, 1) or checkout_simplified not in (0, 1) or webinar_invited not in
    (0, 1)
    or webinar_attended not in (0, 1) or new_product_offer not in (0, 1) or converted_to_sale not
    in (0, 1)) from ventas
union all select 'lead_score_fuera_de_1_99', count(*) filter (where lead_score not between 1 and 99)
  from ventas
union all select 'margen_fuera_de_0_1', count(*) filter (where gross_margin_pct not between 0 and 1)
  from ventas
union all select 'asistio_sin_invitacion', count(*) filter (where webinar_attended > webinar_invited
  ) from ventas
union all select 'dias_cierre_solo_si_hay_venta', count(*) filter (
  where (days_to_close is null) <> (converted_to_sale = 0)) from ventas
union all select 'ingreso_igual_ticket_por_venta', count(*) filter (
  where abs(revenue_eur - aov_eur * converted_to_sale) > 0.01) from ventas
union all select 'utilidad_bruta_igual_ingreso_por_margen', count(*) filter (
  where abs(gross_profit_eur - revenue_eur * gross_margin_pct) > 0.02) from ventas
-- Discovered while profiling: every sale carries a fixed 22 EUR fulfilment cost.
union all select 'contribucion_igual_bruta_menos_costo_menos_22', count(*) filter (
  where abs(contribution_profit_eur - (gross_profit_eur - cost_attributed_eur - 22 *
    converted_to_sale)) > 0.02) from ventas
union all select 'canal_organico_con_presupuesto_ads', count(*) filter (
  where channel not in ('Facebook Ads', 'Google Ads') and es_pago) from ventas
union all select 'canal_pagado_sin_presupuesto_ads', count(*) filter (
  where channel in ('Facebook Ads', 'Google Ads') and not es_pago) from ventas;

```


sql/02_indicadores.sql

```

-- KPI cube in long format: one row per (dimension, valor). Ready for Power BI / Looker.
create or replace view kpi as
with dims as (
    unpivot (
        select transaction_id,
               channel as canal,
               customer_segment as segmento,
               lifecycle_stage as etapa_cliente,
               quarter as trimestre,
               month as mes,
               ad_budget_level as nivel_ads,
               campaign_objective as objetivo_campana,
               geo_region as region,
               device as dispositivo,
               estado_webinar as webinar,
               funnel_completo::varchar as funnel_completo,
               new_product_offer::varchar as oferta_nuevo_producto
        from ventas
    ) on columns(* exclude transaction_id) into name dimension value valor
)
select
    d.dimension,
    d.valor,
    count(*) as oportunidades,
    sum(v.converted_to_sale) as ventas,
    avg(v.converted_to_sale) as conversion,
    sum(v.revenue_eur) as ingresos_eur,
    sum(v.contribution_profit_eur) as contribucion_eur,
    sum(v.cost_attributed_eur) as costo_eur,
    sum(v.cost_attributed_eur) / nullif(sum(v.converted_to_sale), 0) as cac_eur,
    sum(v.revenue_eur) / nullif(sum(v.cost_attributed_eur), 0) as roas,
    sum(v.revenue_eur) / nullif(sum(v.converted_to_sale), 0) as ticket_medio_eur,
    avg(v.contribution_profit_eur) as contribucion_por_oportunidad,
    avg(v.funnel_completo::int) as pct_funnel_completo,
    avg(v.lead_score) as lead_score_medio
from dims d join ventas v using (transaction_id)
group by all
order by d.dimension, d.valor;

-- "Are we growing in a healthy way?": last 12 months vs the 12 before.
create or replace view crecimiento as
with p as (
    select case when date > (select max(date) from ventas) - interval 1 year then 'actual' else '
        anterior' end as periodo, *
    from ventas
    where date > (select max(date) from ventas) - interval 2 year
), m as (
    select periodo,
           count(*)::double as oportunidades,
           sum(converted_to_sale)::double as ventas,
           avg(converted_to_sale) as conversion,
           sum(revenue_eur) as ingresos_eur,
           sum(revenue_eur) / nullif(sum(converted_to_sale), 0) as ticket_medio_eur,
           sum(cost_attributed_eur) as costo_adquisicion_eur,
           sum(cost_attributed_eur) / nullif(sum(converted_to_sale), 0) as cac_eur,
           sum(contribution_profit_eur) as contribucion_eur,
           sum(contribution_profit_eur) / nullif(sum(revenue_eur), 0) as margen_contribucion
    from p group by 1

```

```

), u as (
  unpivot m on columns(* exclude periodo) into name indicador value valor
)
select indicador,
  max(valor) filter (where periodo = 'anterior') as anterior,
  max(valor) filter (where periodo = 'actual') as actual,
  actual / nullif(anterior, 0) - 1 as variacion
from u group by 1;

-- Paid media by budget regime: volume per active campaign-day and attributed vs declared spend.
create or replace view ads_niveles as
with dia as (
  select date, channel, ad_budget_level, count(*) as n,
    avg(campaign_daily_spend_eur) as gasto_declarado, sum(cost_attributed_eur) as
    costo_atribuido
  from ventas where es_pago group by all
)
select
  d.ad_budget_level as nivel_ads,
  count(*) as dias_campana,
  avg(d.n) as oportunidades_por_dia,
  avg(d.gasto_declarado) as gasto_diario_declarado_eur,
  avg(d.costo_atribuido) as costo_diario_atribuido_eur,
  any_value(k.cac_eur) as cac_eur,
  any_value(k.conversion) as conversion,
  any_value(k.lead_score_medio) as lead_score_medio,
  any_value(k.contribucion_por_oportunidad) as contribucion_por_oportunidad
from dia d
join (select ad_budget_level, sum(cost_attributed_eur) / nullif(sum(converted_to_sale), 0) as
  cac_eur,
  avg(converted_to_sale) as conversion, avg(lead_score) as lead_score_medio,
  avg(contribution_profit_eur) as contribucion_por_oportunidad
  from ventas where es_pago group by 1) k using (ad_budget_level)
group by 1
order by gasto_diario_declarado_eur;

```

sql/03_modelo_dimensional.sql

```

-- Dimensional model (star schema) for Power BI / Tableau / Excel pivot tables.
-- Grain of the fact: one commercial opportunity (one row of the original file).
-- Daily campaign spend is not additive (see fact_gasto_campana_dia), so it gets its own fact.

create or replace view dim_fecha as
select distinct
  date as fecha,
  year(date) as anio,
  month as mes,
  quarter as trimestre,
  dayname(date) as dia_semana,
  isodow(date) >= 6 as es_fin_de_semana
from ventas;

create or replace view dim_canal as
select row_number() over (order by channel) as canal_id,
  channel as canal,
  case when channel in ('Facebook Ads', 'Google Ads') then 'Ads pagados'
  else 'Propio / orgánico / afiliados' end as tipo_canal
from (select distinct channel from ventas);

create or replace view dim_campana as

```

```

select row_number() over (order by campaign_objective, ad_budget_level) as campana_id,
       campaign_objective as objetivo_campana,
       ad_budget_level as nivel_presupuesto_ads
from (select distinct campaign_objective, ad_budget_level from ventas);

-- "Junk" dimension: low-cardinality customer attributes combined in one table.
create or replace view dim_perfil as
select row_number() over (order by customer_segment, lifecycle_stage, geo_region, device) as
       perfil_id,
       customer_segment as segmento,
       lifecycle_stage as etapa_cliente,
       geo_region as region,
       device as dispositivo
from (select distinct customer_segment, lifecycle_stage, geo_region, device from ventas);

-- What the customer experienced: funnel variants, webinar, new product.
create or replace view dim_experiencia as
select row_number() over (order by landing, cta, lead_magnet, checkout_simplificado, webinar,
       oferta_nuevo_producto)
       as experiencia_id, *
from (select distinct
       landing_variant as landing,
       cta_variant as cta,
       lead_magnet::bool as lead_magnet,
       checkout_simplified::bool as checkout_simplificado,
       funnel_completo,
       estado_webinar as webinar,
       new_product_offer::bool as oferta_nuevo_producto
       from ventas);

create or replace view fact_oportunidad as
select
       v.transaction_id,
       v.date as fecha,
       c.canal_id,
       k.campana_id,
       p.perfil_id,
       e.experiencia_id,
       v.lead_score,
       v.converted_to_sale as convertida,
       v.days_to_close as dias_cierre,
       v.revenue_eur as ingresos_eur,
       v.gross_margin_pct as margen_bruto_pct,
       v.gross_profit_eur as utilidad_bruta_eur,
       v.cost_attributed_eur as costo_adquisicion_eur,
       22 * v.converted_to_sale as costo_fijo_venta_eur,
       v.contribution_profit_eur as contribucion_eur
from ventas v
join dim_canal c on c.canal = v.channel
join dim_campana k on k.objetivo_campana = v.campaign_objective and k.nivel_presupuesto_ads = v.
       ad_budget_level
join dim_perfil p on (p.segmento, p.etapa_cliente, p.region, p.dispositivo)
       = (v.customer_segment, v.lifecycle_stage, v.geo_region, v.device)
join dim_experiencia e on (e.landing, e.cta, e.lead_magnet, e.checkout_simplificado, e.webinar, e.
       oferta_nuevo_producto)
       = (v.landing_variant, v.cta_variant, v.lead_magnet::bool, v.checkout_simplified
       ::bool,
       v.estado_webinar, v.new_product_offer::bool);

-- campaign_daily_spend_eur is not a disbursement: it takes an almost unique value per row (7,502

```

```

values
-- in 7,868 paid rows) and tracks the budget regime. It is non-additive, so it is kept as the daily
-- average per channel and regime, a reference level to compare regimes, never to be summed.
create or replace view fact_gasto_campana_dia as
select v.date as fecha, c.canal_id, v.ad_budget_level as nivel_presupuesto_ads,
       avg(v.campaign_daily_spend_eur) as gasto_diario_referencia_eur,
       count(*) as oportunidades
from ventas v join dim_canal c on c.canal = v.channel
where v.es_pago
group by all;

-- Star-schema controls: every dimension key is unique and the fact rejoins to the source totals.
-- One row per check; `fallas` must be 0 (asserted by bi.pipeline).
create or replace view control_estrella as
select 'dim_fecha_clave_unica' as regla, count(*) - count(distinct fecha) as fallas from dim_fecha
union all select 'dim_canal_clave_unica', count(*) - count(distinct canal) from dim_canal
union all select 'dim_campana_clave_unica', count(*) - count(distinct (objetivo_campana,
                           nivel_presupuesto_ads)) from dim_campana
union all select 'dim_perfil_clave_unica', count(*) - count(distinct (segmento, etapa_cliente,
                           region, dispositivo)) from dim_perfil
union all select 'dim_experiencia_clave_unica', count(*) - count(distinct (landing, cta, lead_magnet,
                           checkout_simplificado,
                           webinar, oferta_nuevo_producto))
                           from dim_experiencia
union all select 'hechos_filas_distintas_a_ventas',
       abs((select count(*) from fact_oportunidad f join dim_fecha using (fecha)) - (select count(*)
       from ventas))
union all select 'hechos_ingresos_distintos_a_ventas',
       (abs((select sum(ingresos_eur) from fact_oportunidad) - (select sum(revenue_eur) from ventas)) >
       0.01)::int
union all select 'hechos_contribucion_distinta_a_ventas',
       (abs((select sum(contribucion_eur) from fact_oportunidad) - (select sum(contribution_profit_eur)
       from ventas)) > 0.01)::int;

```