

Proyecto integrador de Inteligencia de Negocios

Cómo usar los datos de ventas para decidir en qué invertir

2026-10-07

Contenido

El proceso en una página.....	3
En cinco frases.....	3
Glosario mínimo.....	4
Fase 1. El problema y las preguntas	5
La situación	5
Las preguntas que guían el análisis.....	5
Fase 2. Preparar y validar los datos	6
Qué datos tenemos.....	6
Doce revisiones automáticas	6
Lo que encontramos al limpiar.....	7
Fase 3. Modelo analítico e indicadores	8
3.1 Organizar los datos: esquema estrella.....	8
3.2 Indicadores	8
3.3 El modelo: ¿qué hace que alguien compre?	8
3.4 De la predicción a la decisión	9
Fase 4. Resultados	11
4.1 ¿El negocio está creciendo bien? (P1).....	11
4.2 ¿Dónde está el valor? (P2)	12
4.3 ¿Qué explica la mejora? (P3)	13
4.4 ¿Más publicidad trae más ganancia? (P4)	13
4.5 ¿Funciona el modelo? (P5).....	14
4.6 ¿Qué opción conviene? (P6)	14
Fase 5. Hallazgos y recomendación.....	16
Hallazgos	16
Recomendación a la gerencia.....	16
Preguntas difíciles que esperamos	16
Anexo A. Diccionario de variables.....	17
Anexo B. Cómo reproducir todo.....	18
Anexo: código SQL del proceso	19
sql/01_preparacion.sql	19
sql/02_indicadores.sql	19
sql/03_modelo_estrella.sql	21

Este documento cuenta, paso a paso, cómo pasamos de un archivo de 20.000 filas a una recomendación para la gerencia. Está escrito para leerse sin formación financiera: cada término se explica la primera vez que aparece y hay un glosario corto al inicio.

Datos: `data/original/dataset_ventas_transaccional_sintetico_es.csv` (sintético, montos en euros, enero de 2024 a abril de 2026). Cada número del informe indica de qué tabla sale y se puede regenerar con `make run`.

El proceso en una página

Seguimos el ciclo clásico de un proyecto de ciencia de datos, adaptado a inteligencia de negocios:

Paso	Pregunta que responde	Qué hicimos	Dónde
1. Entender el negocio	¿Qué hay que decidir?	Definir la decisión y 6 preguntas	Fase 1
2. Entender y limpiar los datos	¿Podemos confiar en los datos?	12 revisiones automáticas en SQL y 7 problemas resueltos	Fase 2
3. Organizar y medir	¿Cómo va el negocio?	Esquema estrella e indicadores	Fase 3
4. Modelar	¿Qué hace que alguien compre?	Modelo que predice la probabilidad de compra	Fase 3
5. Simular	¿Qué pasaría con cada opción?	“¿Qué habría pasado si...?” + 10.000 simulaciones	Fases 3 y 4
6. Comunicar	¿Qué hacemos?	Hallazgos, recomendación y límites	Fase 5

```
archivo original (no se toca)
  -> SQL: limpiar y validar          sql/01_preparacion.sql
  -> SQL: indicadores y estrella     sql/02_indicadores.sql, sql/03_modelo_estrella.sql
  -> Python: modelo + simulación    src/bi/model.py
  -> gráficas + informe             src/bi/plots.py, informe/
```

En cinco frases

- El negocio va bien:** en el último año hubo 76 % más ventas y la ganancia neta casi se duplicó (+92 %).
- La mejora vino de convertir mejor,** no de atraer más gente: el porcentaje de interesados que compra pasó de 9 % a 12 %, justo cuando se adoptó una versión mejorada del recorrido de compra (el “funnel”).
- Gastar más en publicidad no sirve:** con el gasto más alto, conseguir una venta cuesta casi 5 veces más.
- Recomendación:** llevar el funnel mejorado a todos los clientes (ganancia esperada de €120 mil al año, casi sin riesgo) y probar el nuevo producto en un piloto antes de lanzarlo en grande.

5. **Límite:** los datos son sintéticos; el método se puede reutilizar, las cifras no describen una empresa real.

Glosario mínimo

Término	Qué significa aquí
Oportunidad	Una persona interesada que podría comprar. Es cada fila de la tabla
Conversión	Porcentaje de oportunidades que terminan en compra
Ticket	Valor promedio de una venta
Ganancia neta	Lo que queda de una venta después de pagar el producto, la publicidad y el envío. Es la medida de valor de todo el informe
Costo por venta	Cuánto se gasta en publicidad para conseguir una venta (en marketing se le llama CAC)
Funnel	El recorrido de compra en la web: página de llegada, botón, regalo descargable y pago
Fuga de información	Usar en un modelo datos que solo se conocen después del resultado. El modelo parece bueno y falla en la práctica
“¿Qué habría pasado si...?”	Usar el modelo para estimar el resultado de un cambio que no ocurrió (en estadística, contrafactual)
Simulación Monte Carlo	Repetir un cálculo miles de veces con supuestos que varían, para ver todos los resultados posibles y no solo uno
Escenario pesimista / optimista	En 9 de cada 10 simulaciones se gana al menos el pesimista; solo en 1 de cada 10 se supera el optimista (percentiles 10 y 90)

Fase 1. El problema y las preguntas

La situación

Una empresa que vende en línea en España y Latinoamérica registra cada oportunidad: por qué canal llegó (email, Google, Facebook...), qué tipo de cliente es, qué versión de la web vio, si fue invitada a un webinar, si se le ofreció un producto nuevo y si al final compró.

La gerencia está considerando cuatro opciones para el próximo año:

Opción	En qué consiste
Mejorar el funnel	Usar en toda la web la página, el botón, el regalo descargable y el pago simplificado que ya se probaron
Webinars	Invitar a un webinar a todos los clientes que ya conocen la marca
Duplicar publicidad	Doblar el gasto diario en Facebook y Google
Nuevo producto	Ofrecer un producto premium, más caro

¿Por qué medimos ganancia neta y no ventas? Una venta que cuesta €900 de publicidad y deja €800 sube las ventas, pero hace perder dinero. La ganancia neta ya descuenta esos costos.

Las preguntas que guían el análisis

#	Pregunta	Por qué importa
P1	¿El negocio está creciendo bien?	Antes de invertir hay que saber si lo actual funciona
P2	¿Qué canales y clientes dejan más ganancia?	Mucho volumen no siempre es mucho valor
P3	¿Qué explica la mejora de 2025?	Si fue el funnel, extenderlo es la decisión obvia
P4	¿Más publicidad trae más ganancia?	Es la opción más tentadora y la más cara
P5	¿Qué hace que una persona compre?	Para comparar opciones hay que saber qué mueve la compra
P6	¿Qué opción deja más ganancia y con qué riesgo?	Es la decisión que hay que tomar

Fase 2. Preparar y validar los datos

Regla de oro: el archivo original nunca se modifica (está guardado como solo lectura). Toda limpieza se hace con consultas SQL que crean una versión limpia aparte (`sql/01_preparacion.sql`). Así cualquiera puede revisar qué se hizo y volver al dato original.

Qué datos tenemos

20.000 filas y 28 columnas, que se agrupan en seis familias (el detalle de cada columna está en el Anexo A):

Familia	Ejemplos	Para qué la usamos
Identificación y tiempo	id, fecha, mes, trimestre	Contar sin duplicar y ver la evolución
Quién es el cliente	tipo de cliente, etapa, país, dispositivo	Comparar grupos
De dónde llegó	canal, objetivo de campaña, nivel de gasto en publicidad	Medir el valor de cada canal
Qué vivió (las palancas)	versión de página, botón, regalo, pago simplificado, webinar, producto nuevo	Lo que la empresa puede cambiar
Qué pasó	compró o no, días hasta cerrar	El resultado que queremos explicar
Cuánto valió y costó	ingreso, margen, costo de publicidad, ganancia neta	Medir el valor

Además creamos tres columnas que simplifican el análisis: si vio el **funnel mejorado completo**, si llegó por **publicidad pagada** y su **estado en el webinar** (no invitado, invitado, asistió).

Doce revisiones automáticas

Cada revisión cuenta cuántas filas tienen un problema (`salidas/validacion.csv`). **Las doce dieron cero.**

Qué se revisa	Por qué
Que no haya oportunidades repetidas	Una fila duplicada infla las ventas
Que no falten datos clave (canal, fecha, resultado)	Sin ellos la fila no sirve
Que el mes coincida con la fecha	Si no, los totales por mes y por día no cuadran
Que los valores sean posibles: puntajes entre 1 y 99, márgenes entre 0 y 1, sí/no solo como 0/1	Un valor imposible distorsiona los promedios
Que las columnas sean coherentes: nadie asiste a un webinar sin invitación, solo hay "días hasta cerrar" si hubo compra, el ingreso es cero si no hubo venta, y las ganancias cuadran con ingresos y costos	Detecta errores de registro

Lo que encontramos al limpiar


Que las revisiones den cero no significa que el dato esté listo. Estos siete puntos cambian las conclusiones si se ignoran:

#	Qué vimos	Por qué importa	Qué hicimos
1	Un costo escondido. La ganancia neta no cuadraba en 2.096 filas: todas eran ventas y siempre faltaban €22	Sin entenderlo, parece un error de cálculo	Era un costo fijo por venta (por ejemplo, envío). Lo documentamos como regla del negocio
2	Un dato repetido. El gasto diario de cada campaña aparece en todas las oportunidades de ese día	Sumarlo fila por fila da €4,55 millones; el gasto real es €854 mil (5 veces menos)	Lo pasamos a una tabla aparte, con una fila por campaña y día
3	Dos gastos que no coinciden. El gasto de campaña declarado (€854 mil) es 7 veces el asignado a las oportunidades (€117 mil)	Si el verdadero es el declarado, la publicidad es aún menos rentable	Usamos el asignado, que es el que entra en la ganancia, y lo dejamos como pregunta abierta
4	Ceros y vacíos que no son errores. El ticket vale 0 y los días hasta cerrar están vacíos cuando no hubo venta (90 % de las filas)	Promediar el ticket en todas las filas da €116 en vez de ~€1.100	El ticket se calcula solo sobre ventas, y los vacíos no se rellenan
5	Datos del futuro. Ingreso, margen y días hasta cerrar se conocen después de la compra	Si el modelo los usa, "adivina" la compra con información de la compra	Los sacamos del modelo (fuga de información)
6	Un producto que solo se ofreció a algunos. El producto nuevo solo se ofreció a clientes B2B Services, Ecommerce y Enterprise, que ya compran caro	Comparar "con oferta vs. sin oferta" le atribuye al producto el valor del tipo de cliente	Comparamos dentro de cada tipo de cliente y no suponemos efectos en quienes nunca lo recibieron
7	Cambios que coinciden en el tiempo. El nivel de publicidad y el funnel cambiaron por periodos; además 2026T2 solo tiene abril	Comparar promedios mezcla el efecto de la palanca con el del momento	El modelo compara oportunidades del mismo trimestre y las gráficas avisan del trimestre incompleto

Fase 3. Modelo analítico e indicadores

3.1 Organizar los datos: esquema estrella

En BI no se trabaja con una sola tabla gigante. Se separa en una **tabla de hechos** (lo que se mide: si compró, cuánto pagó, cuánto costó) y **tablas de consulta** o dimensiones (por dónde se corta: fecha, canal, cliente, experiencia). Así es como mejor funcionan Power BI, Tableau o una tabla dinámica.



Control de calidad: al volver a unir las tablas se obtienen exactamente los totales del archivo original (20.000 filas, €2,33 millones de ingresos), y una prueba automática lo verifica. Las tablas quedan exportadas en `data/modelo_estrella/` (`sql/03_modelo_estrella.sql`).

3.2 Indicadores

Indicador	Pregunta que responde	Cómo se calcula
Conversión	¿Qué tan bien convencemos?	ventas / oportunidades
Ticket	¿Cuánto vale cada venta?	ingresos / ventas
Costo por venta	¿Cuánto cuesta conseguir una venta?	gasto en publicidad / ventas
Ganancia neta por oportunidad	¿Cuánto vale cada interesado que llega?	ganancia neta / oportunidades
% con funnel mejorado	¿Cuánto se ha adoptado la mejora?	oportunidades con las 4 mejoras / total
Ganancia esperada y probabilidad de perder	¿Qué opción conviene y qué tan segura es?	Simulación (3.4)

La **ganancia neta por oportunidad** es el indicador más útil: resume en un número si la gente compra, cuánto paga y cuánto costó traerla. Todos los indicadores están calculados por canal, cliente, país, mes y trimestre en `salidas/kpi.csv`, listos para cualquier herramienta de BI.

3.3 El modelo: ¿qué hace que alguien compre?

Objetivo. Estimar, para cada oportunidad, la probabilidad de que compre.

Por qué este modelo. Usamos una **regresión logística**, uno de los modelos más simples para predecir un sí o un no. La elegimos porque el efecto de cada variable se puede explicar en una frase: para comparar opciones necesitamos entender el modelo, no solo que acierte.

Qué variables usa. Solo las que se conocen antes de la compra: canal, tipo de cliente, país, dispositivo, nivel de publicidad, palancas del funnel, webinar, oferta de producto, puntaje previo del interesado y trimestre. Quedan fuera las que tienen fuga de información (problema 5).

Cómo lo evaluamos. Lo entrenamos con 2024 y 2025 y lo probamos con 2026, un periodo que nunca vio. Es la prueba honesta, porque así se va a usar: para predecir lo que viene.

Medida	Resultado	Cómo leerlo
AUC	0,745	Si se toman al azar una persona que compró y una que no, el modelo le da mayor puntaje a la que compró 3 de cada 4 veces (adivinar sería 1 de cada 2)
10 % con mayor puntaje	compra el 33,5 %	2,6 veces el promedio de 2026 (12,8 %)
20 % con mayor puntaje	reúne el 43 % de las ventas	Atenderlos primero rinde más del doble que atender al azar

Fuente: `salidas/lift_2026.csv`.

Qué aprendió. Cuánto cambian las chances de compra con cada factor, dejando todo lo demás igual (`salidas/drivers.csv`; “chances” = probabilidad de comprar dividida entre la de no comprar):

Factor	Efecto en las chances de compra
Puntaje previo del interesado (16 puntos más)	+82 %
Asistir al webinar (además de ser invitado)	+43 %
Botón que explica el beneficio	+24 %
Página de llegada nueva	+17 %
Regalo descargable	+16 %
Pago simplificado	+5 %
Publicidad en nivel saturado (frente a medio)	-49 %
Ofrecer el producto nuevo	-38 % (compran menos, pero cada venta vale el doble)

3.4 De la predicción a la decisión

El modelo dice qué mueve la compra. Para decidir hacen falta tres pasos más:

1. “¿Qué habría pasado si...?” Tomamos las 10.073 oportunidades del último año y le pedimos al modelo la ganancia esperada con cada opción aplicada:
 - Funnel: todas ven las cuatro mejoras.
 - Webinars: los 3.334 clientes conocidos que no fueron invitados reciben invitación y asiste 1 de cada 4, como en el pasado.
 - Producto: se ofrece a los 5.858 clientes de los tres tipos donde hay evidencia.
 - Publicidad: como el gasto ya fue alto o saturado en algunos periodos, usamos lo que pasó entonces.

2. **Incertidumbre de los datos.** Repetimos todo el cálculo 200 veces, cada vez con una muestra distinta de las mismas filas (bootstrap). Si el resultado cambia mucho entre repeticiones, la evidencia es débil.
3. **Incertidumbre de la ejecución.** Ninguna iniciativa sale exactamente como se planea. Corremos 10.000 simulaciones en las que varían el costo de implementarla y a cuánta gente llega:

Opción	Costo de implementación (mínimo / probable / máximo)	A cuánta gente llega
Funnel	€8 mil / €12 mil / €20 mil	70 a 100 %
Webinars	€9,6 mil / €14,4 mil / €24 mil (12 sesiones al año)	50 a 100 %
Publicidad	€0 / €2 mil / €5 mil (gestión; el gasto en anuncios ya está en los datos)	100 %
Producto	€15 mil / €25 mil / €45 mil	30 a 90 %

Estos costos **son supuestos nuestros, no salen de los datos**. Por eso en la Fase 4 decimos cuánto tendrían que cambiar para que cambie la recomendación.

Fase 4. Resultados

4.1 ¿El negocio está creciendo bien? (P1)

Último año (mayo 2025 a abril 2026) frente al año anterior (salidas/crecimiento.csv):

Indicador	Año anterior	Último año	Cambio
Oportunidades	7.680	10.073	+31 %
Ventas	694	1.224	+76 %
Conversión	9,0 %	12,2 %	+3,2 puntos
Costo por venta	€81	€66	-18 %
Ganancia neta	€487 mil	€934 mil	+92 %

Lectura: las ventas crecen más que los interesados y la ganancia más que las ventas. Es crecimiento por eficiencia, el más sano. La alerta: el gasto total en publicidad sube 44 %, y ese dato no es del todo confiable (problema 3).




Figura 1. Ingresos y ganancia neta por mes. Fuente: kpi , dimensión mes.

4.2 ¿Dónde está el valor? (P2)




Figura 2. Ganancia neta por oportunidad y conversión por canal. Fuente: kpi, dimensión canal.

- Facebook y Google traen el **39 %** de los interesados, pero solo el **13 %** de la ganancia.
- Email, SEO (blog) y Webinar traen el **40 %** de los interesados y el **69 %** de la ganancia.
- Los clientes Enterprise son el **10 %** de los interesados y dejan el **24 %** de la ganancia.
- España reúne el **47 %** de los ingresos, pero todos los países son igual de rentables, así que el país no cambia la decisión (`salidas/pivote_ingresos_region_segmento.csv`).

4.3 ¿Qué explica la mejora? (P3)




Figura 3. Conversión y adopción del funnel mejorado por trimestre (2026T2 solo incluye abril). Fuente: `kpi`, dimensión trimestre.

- **Hecho:** la conversión salta de ~9 % a ~13 % en el tercer trimestre de 2025, el mismo en que el funnel mejorado pasa de 0 % a 16 % de las oportunidades.
- **Explicación probable:** el funnel mejorado.
- **¿Por qué no es casualidad?** El modelo compara oportunidades con y sin las mejoras dentro del mismo trimestre, canal y tipo de cliente, y las mejoras siguen aumentando la compra (3.3).
- **Pendiente:** confirmar que no hubo otros cambios en esas fechas (precios, equipo de ventas).

4.4 ¿Más publicidad trae más ganancia? (P4)

Más publicidad, peor resultado (Facebook + Google, por nivel de gasto diario)




Figura 4. Costo por venta y ganancia por oportunidad según el nivel de gasto en publicidad. Fuente: `ads_niveles`.

No. Pasar del gasto medio (el actual) al saturado multiplica el gasto por 2,5, pero los interesados solo por 1,3, y además son de menor calidad (puntaje promedio de 52,5 a 37,8). Resultado: cada venta cuesta €853 en vez de €178, y cada interesado deja -€3 en lugar de €36 (salidas/ads_niveles.csv).

4.5 ¿Funciona el modelo? (P5)




Figura 5. Porcentaje que compró en 2026 según el puntaje del modelo entrenado con 2024-2025. Fuente: salidas/lift_2026.csv.

Sí: quienes tienen mejor puntaje compran mucho más. Además de servir para decidir la inversión, el modelo le dice al equipo comercial a quién llamar primero.

4.6 ¿Qué opción conviene? (P6)




Figura 6. Ganancia extra a 12 meses por opción, en 10.000 simulaciones. El punto es el valor central; la barra va del escenario pesimista al optimista. Fuente: salidas/montecarlo_resumen.csv.

Opción	Ganancia esperada en 12 meses	Pesimista	Optimista	Probabilidad de perder
Nuevo producto (3 tipos de cliente)	€175 mil	€75 mil	€285 mil	0,1 %
Mejorar el funnel	€120 mil	€77 mil	€166 mil	0 %
Webinars	€32 mil	€8 mil	€56 mil	3,9 %
Duplicar publicidad	-€101 mil	-€158 mil	-€45 mil	99,5 %

Cómo leerla:

- **El producto** tiene la mayor ganancia esperada, pero también el rango más amplio: es la apuesta menos segura.
- **El funnel** gana un poco menos, pero con un rango estrecho y sin escenarios de pérdida: es la apuesta más segura.
- **Duplicar publicidad** pierde dinero en casi todas las simulaciones.
- **No son excluyentes.** El funnel mejora la conversión y el producto el valor de cada venta; se pueden hacer los dos.

¿Cuándo cambiaría la recomendación?

- Si lanzar el producto cuesta más de **€84 mil**, el funnel pasa a ser la mejor opción.
- Los webinars solo valen la pena si el programa cuesta menos de **€48 mil** al año.

Fase 5. Hallazgos y recomendación

Hallazgos

Separamos lo que muestran los datos (hecho), lo que creemos que lo explica (interpretación) y lo que falta confirmar:

Hecho	Explicación probable	Falta confirmar
La conversión subió de 9 % a 12 % y el costo por venta bajó 18 %	El funnel mejorado	Otros cambios en las mismas fechas
La publicidad trae el 39 % de los interesados y solo el 13 % de la ganancia	Más gasto compra tráfico de peor calidad	Cuál de los dos gastos registrados es el real
El producto nuevo duplica la ganancia por venta dentro de cada tipo de cliente	Es un producto premium (€2.827 frente a €1.064)	Solo hay ~55 ventas: puede ser novedad o quitarle ventas a otros productos
Asistir al webinar aumenta las chances de compra un 43 %, pero solo asiste 1 de cada 4 invitados	El valor está en que asistan, no en invitar	El costo real de cada sesión

Recomendación a la gerencia

1. **Ahora: funnel mejorado para todos.** Hoy solo lo ve el 19 % de las oportunidades. Es la opción con mejor relación entre ganancia y seguridad, y la que tiene más evidencia (cuatro trimestres).
2. **En paralelo: piloto del producto nuevo** en B2B Services, Ecommerce y Enterprise durante un trimestre, ofreciéndolo a un grupo elegido al azar y comparándolo con otro que no lo recibe. Escalarlo solo si el piloto confirma la mejora.
3. **No duplicar la publicidad.** Mantener el nivel actual y aclarar con finanzas por qué los dos registros de gasto no coinciden.
4. **Webinars, solo si cuestan menos de €48 mil al año,** y medir cuántos asisten, no cuántos se invitan.
5. **Usar el puntaje del modelo** para que el equipo comercial atienda primero a los más probables.

Preguntas difíciles que esperamos

Pregunta	Respuesta
¿Por qué no comparar promedios y ya?	Porque mezclan el efecto de la palanca con el tipo de cliente y el momento. Con promedios simples, el producto parecía valer el doble de lo que estimamos al comparar dentro de cada tipo de cliente
¿Cómo saben que el modelo no hace trampa?	No usa datos posteriores a la compra y se probó en 2026, un año que no vio al entrenar
¿Y si los costos supuestos están mal?	Por eso decimos cuándo cambia la recomendación: el producto tendría que costar más de €84 mil

Pregunta	Respuesta
¿Por qué no coincide con el ejercicio original del caso?	El caso original estimaba que duplicar la publicidad ganaba €31 mil y que el producto bajaba la compra un 25 %. El histórico muestra que el gasto saturado pierde dinero y que, dentro de cada tipo de cliente, el producto baja la conversión entre 0 y 3,3 puntos
¿Sirve para una empresa real?	El método sí; las cifras no, porque los datos son sintéticos

Anexo A. Diccionario de variables

Variable	Tipo	Qué representa	Uso
transaction_id	Identificador	Una oportunidad (una fila)	Validar que no haya repetidos
date	Fecha	Día de la oportunidad	Evolución en el tiempo
month, quarter	Fecha (derivada)	Mes y trimestre	Se valida que coincidan con la fecha
channel	Categoría	Canal de llegada (7)	Dimensión principal
campaign_objective	Categoría	Objetivo de la campaña (captar, nutrir, recuperar...)	Dimensión
customer_segment	Categoría	Tipo de cliente (B2B Services, Enterprise, Ecommerce, Creator, SMB)	Dimensión; valor de cada venta
lifecycle_stage	Categoría	Visitante nuevo, contacto conocido o cliente que vuelve	Define a quién invitar al webinar
device, geo_region	Categoría	Dispositivo y país	Dimensiones
ad_budget_level	Categoría ordenada	Nivel de gasto en publicidad (bajo → saturado)	Solo en canales pagados
campaign_daily_spend_eur	Número	Gasto diario de la campaña	Se repite por fila (problema 2)
cost_attributed_eur	Número	Costo de publicidad asignado a la oportunidad	Entra en la ganancia; fuera del modelo
landing_variant, cta_variant	Categoría	Versión de la página y del botón	Palancas del funnel
lead_magnet, checkout_simplified	Sí/No	Recibió el regalo / pago simplificado	Palancas del funnel
webinar_invited, webinar_attended	Sí/No	Invitado / asistió al webinar	Palanca webinar
new_product_offer	Sí/No	Se le ofreció el producto nuevo	Palanca producto
lead_score	Número (1-99)	Puntaje previo del interesado	Variable más predictiva
converted_to_sale	Sí/No	Compró	Lo que el modelo predice
days_to_close	Número	Días hasta la compra	Solo si compró; fuera del modelo (fuga)
aov_eur, revenue_eur	Número	Ticket e ingreso (iguales; 0 si no compró)	Indicadores

Variable	Tipo	Qué representa	Uso
gross_margin_pct, gross_profit_eur	Número	Margen y ganancia bruta	Indicadores; fuera del modelo
contribution_profit_eur	Número	Ganancia neta	Medida de valor del informe

Anexo B. Cómo reproducir todo

```
make install # crea el entorno
make test   # 8 pruebas automáticas
make run     # limpia, calcula, entrena, simula y regenera tablas y gráficas (~2 min)
make pdf     # regenera este documento
```

Archivo	Contenido
sql/01_preparacion.sql	Versión limpia de los datos y las 12 revisiones
sql/02_indicadores.sql	Indicadores, crecimiento y publicidad por nivel de gasto
sql/03_modelo_estrella.sql	Esquema estrella
src/bi/model.py	Modelo, “¿qué habría pasado si...?”, simulación y supuestos de costo
src/bi/pipeline.py	Ejecuta todo de principio a fin
src/bi/plots.py	Gráficas
salidas/	Tablas de resultados citadas en este documento

Anexo: código SQL del proceso

sql/01_preparacion.sql

```
-- Expects a view/table `raw` with the original CSV (see bi.pipeline.connect).
-- The original file is never modified: everything here is a view.

create or replace view ventas as
select
  * replace (cast(date as date) as date),
  landing_variant = 'landing_v2' and cta_variant = 'benefit_cta'
  and lead_magnet = 1 and checkout_simplified = 1 as funnel_completo,
  ad_budget_level <> 'organic_or_owned' as es_pago,
  case when webinar_attended = 1 then 'asistio'
        when webinar_invited = 1 then 'invitado'
        else 'no_invitado' end as estado_webinar
from raw;

-- One row per rule; `fallas` = rows breaking it. All must be 0 before analysis.
create or replace view validacion as
select 'id_duplicado' as regla, count(*) - count(distinct transaction_id) as fallas from ventas
union all select 'nulos_en_campos_clave', count(*) filter (
  where transaction_id is null or date is null or channel is null
  or converted_to_sale is null or contribution_profit_eur is null) from ventas
union all select 'mes_distinto_a_fecha', count(*) filter (where month <> strftime(date, '%Y-%m'))
  from ventas
union all select 'binarios_fuera_de_0_1', count(*) filter (
  where lead_magnet not in (0, 1) or checkout_simplified not in (0, 1) or webinar_invited not in
  (0, 1)
  or webinar_attended not in (0, 1) or new_product_offer not in (0, 1) or converted_to_sale
  not in (0, 1)) from ventas
union all select 'lead_score_fuera_de_1_99', count(*) filter (where lead_score not between 1 and
  99) from ventas
union all select 'margen_fuera_de_0_1', count(*) filter (where gross_margin_pct not between 0 and
  1) from ventas
union all select 'asistio_sin_invitacion', count(*) filter (where webinar_attended >
  webinar_invited) from ventas
union all select 'dias_cierre_solo_si_hay_venta', count(*) filter (
  where (days_to_close is null) <> (converted_to_sale = 0)) from ventas
union all select 'ingreso_igual_ticket_por_venta', count(*) filter (
  where abs(revenue_eur - aov_eur * converted_to_sale) > 0.01) from ventas
union all select 'utilidad_bruta_igual_ingreso_por_margen', count(*) filter (
  where abs(gross_profit_eur - revenue_eur * gross_margin_pct) > 0.02) from ventas
-- Discovered while profiling: every sale carries a fixed 22 EUR fulfilment cost.
union all select 'contribucion_igual_bruta_menos_costo_menos_22', count(*) filter (
  where abs(contribution_profit_eur - (gross_profit_eur - cost_attributed_eur - 22 *
  converted_to_sale)) > 0.02) from ventas
union all select 'canal_organico_con_presupuesto_ads', count(*) filter (
  where channel not in ('Facebook Ads', 'Google Ads') and es_pago) from ventas;
```

sql/02_indicadores.sql

```
-- KPI cube in long format: one row per (dimension, valor). Ready for Power BI / Looker.
create or replace view kpi as
with dims as (
  unpivot (
    select transaction_id,
           channel as canal,
           customer_segment as segmento,
           lifecycle_stage as etapa_cliente,
```

```

        quarter                as trimestre,
        month                   as mes,
        ad_budget_level         as nivel_ads,
        campaign_objective      as objetivo_campana,
        geo_region              as region,
        device                   as dispositivo,
        estado_webinar          as webinar,
        funnel_completo::varchar as funnel_completo,
        new_product_offer::varchar as oferta_nuevo_producto

    from ventas
) on columns(* exclude transaction_id) into name dimension value valor
)
select
    d.dimension,
    d.valor,
    count(*) as oportunidades,
    sum(v.converted_to_sale) as ventas,
    avg(v.converted_to_sale) as conversion,
    sum(v.revenue_eur) as ingresos_eur,
    sum(v.contribution_profit_eur) as contribucion_eur,
    sum(v.cost_attributed_eur) as costo_eur,
    sum(v.cost_attributed_eur) / nullif(sum(v.converted_to_sale), 0) as cac_eur,
    sum(v.revenue_eur) / nullif(sum(v.cost_attributed_eur), 0) as roas,
    sum(v.revenue_eur) / nullif(sum(v.converted_to_sale), 0) as ticket_medio_eur,
    avg(v.contribution_profit_eur) as contribucion_por_oportunidad,
    avg(v.funnel_completo::int) as pct_funnel_completo,
    avg(v.lead_score) as lead_score_medio
from dims d join ventas v using (transaction_id)
group by all
order by d.dimension, d.valor;

-- "Are we growing in a healthy way?": last 12 months vs the 12 before.
create or replace view crecimiento as
with p as (
    select case when date > (select max(date) from ventas) - interval 1 year then 'actual' else
        'anterior' end as periodo, *
    from ventas
    where date > (select max(date) from ventas) - interval 2 year
), m as (
    select periodo,
        count(*)::double as oportunidades,
        sum(converted_to_sale)::double as ventas,
        avg(converted_to_sale) as conversion,
        sum(revenue_eur) as ingresos_eur,
        sum(revenue_eur) / nullif(sum(converted_to_sale), 0) as ticket_medio_eur,
        sum(cost_attributed_eur) as costo_adquisicion_eur,
        sum(cost_attributed_eur) / nullif(sum(converted_to_sale), 0) as cac_eur,
        sum(contribution_profit_eur) as contribucion_eur,
        sum(contribution_profit_eur) / nullif(sum(revenue_eur), 0) as margen_contribucion
    from p group by 1
), u as (
    unpivot m on columns(* exclude periodo) into name indicador value valor
)
select indicador,
    max(valor) filter (where periodo = 'anterior') as anterior,
    max(valor) filter (where periodo = 'actual') as actual,
    actual / nullif(anterior, 0) - 1 as variacion
from u group by 1;

-- Paid media by budget regime: volume per active campaign-day and attributed vs declared spend.
create or replace view ads_niveles as
with dia as (
    select date, channel, ad_budget_level, count(*) as n,
        avg(campaign_daily_spend_eur) as gasto_declarado, sum(cost_attributed_eur) as
        costo_atribuido

```

```

        from ventas where es_pago group by all
    )
select
    d.ad_budget_level                as nivel_ads,
    count(*)                        as dias_campana,
    avg(d.n)                        as oportunidades_por_dia,
    avg(d.gasto_declarado)          as gasto_diario_declarado_eur,
    avg(d.costo_atribuido)         as costo_diario_atribuido_eur,
    any_value(k.cac_eur)            as cac_eur,
    any_value(k.conversion)         as conversion,
    any_value(k.lead_score_medio)   as lead_score_medio,
    any_value(k.contribucion_por_oportunidad) as contribucion_por_oportunidad
from dia d
join (select ad_budget_level, sum(cost_attributed_eur) / nullif(sum(converted_to_sale), 0) as
    cac_eur,
        avg(converted_to_sale) as conversion, avg(lead_score) as lead_score_medio,
        avg(contribution_profit_eur) as contribucion_por_oportunidad
    from ventas where es_pago group by 1) k using (ad_budget_level)
group by 1
order by gasto_diario_declarado_eur;

```

sql/03_modelo_estrella.sql

```

-- Dimensional model (star schema) for Power BI / Tableau / Excel pivot tables.
-- Grain of the fact: one commercial opportunity (one row of the original file).
-- Campaign spend lives at a different grain (campaign-day), so it gets its own fact.

create or replace view dim_fecha as
select distinct
    date            as fecha,
    year(date)      as anio,
    month           as mes,
    quarter         as trimestre,
    dayname(date)   as dia_semana,
    isodow(date) >= 6 as es_fin_de_semana
from ventas;

create or replace view dim_canal as
select row_number() over (order by channel) as canal_id,
    channel as canal,
    case when channel in ('Facebook Ads', 'Google Ads') then 'Ads pagados'
    else 'Propio / orgánico / afiliados' end as tipo_canal
from (select distinct channel from ventas);

create or replace view dim_campana as
select row_number() over (order by campaign_objective, ad_budget_level) as campana_id,
    campaign_objective as objetivo_campana,
    ad_budget_level as nivel_presupuesto_ads
from (select distinct campaign_objective, ad_budget_level from ventas);

-- "Junk" dimension: low-cardinality customer attributes combined in one table.
create or replace view dim_perfil as
select row_number() over (order by customer_segment, lifecycle_stage, geo_region, device) as
    perfil_id,
    customer_segment as segmento,
    lifecycle_stage as etapa_cliente,
    geo_region as region,
    device as dispositivo
from (select distinct customer_segment, lifecycle_stage, geo_region, device from ventas);

-- What the customer experienced: funnel variants, webinar, new product.
create or replace view dim_experiencia as

```

```

select row_number() over (order by landing, cta, lead_magnet, checkout_simplificado, webinar,
                           oferta_nuevo_producto)
       as experiencia_id, *
from (select distinct
      landing_variant      as landing,
      cta_variant          as cta,
      lead_magnet::bool    as lead_magnet,
      checkout_simplified::bool as checkout_simplificado,
      funnel_completo,
      estado_webinar       as webinar,
      new_product_offer::bool as oferta_nuevo_producto
      from ventas);

create or replace view fact_oportunidad as
select
  v.transaction_id,
  v.date           as fecha,
  c.canal_id,
  k.campana_id,
  p.perfil_id,
  e.experiencia_id,
  v.lead_score,
  v.converted_to_sale      as convertida,
  v.days_to_close         as dias_cierre,
  v.revenue_eur           as ingresos_eur,
  v.gross_margin_pct      as margen_bruto_pct,
  v.gross_profit_eur      as utilidad_bruta_eur,
  v.cost_attributed_eur   as costo_adquisicion_eur,
  22 * v.converted_to_sale as costo_fijo_venta_eur,
  v.contribution_profit_eur as contribucion_eur
from ventas v
join dim_canal c      on c.canal = v.channel
join dim_campana k    on k.objetivo_campana = v.campaign_objective and k.nivel_presupuesto_ads =
  v.ad_budget_level
join dim_perfil p      on (p.segmento, p.etapa_cliente, p.region, p.dispositivo)
  = (v.customer_segment, v.lifecycle_stage, v.geo_region, v.device)
join dim_experiencia e on (e.landing, e.cta, e.lead_magnet, e.checkout_simplificado, e.webinar,
  e.oferta_nuevo_producto)
  = (v.landing_variant, v.cta_variant, v.lead_magnet::bool,
  v.checkout_simplified::bool,
  v.estado_webinar, v.new_product_offer::bool);

-- campaign_daily_spend_eur repeats on every opportunity of the same campaign-day:
-- summing it per row would multiply the spend. Its true grain is (date, channel).
create or replace view fact_gasto_campana_dia as
select v.date as fecha, c.canal_id, v.ad_budget_level as nivel_presupuesto_ads,
       avg(v.campaign_daily_spend_eur) as gasto_declarado_eur,
       count(*) as oportunidades
from ventas v join dim_canal c on c.canal = v.channel
where v.es_pago
group by all;

```